

金泽昊

zehaojin.com | lunamos.thu@gmail.com | +86 15618935203



教育背景

2026 - 2027	佐治亚理工学院 计算科学与工程，硕士（GPA: 4.0/4.0，预计 2027 年 5 月毕业）	美国，亚特兰大
2021 - 2025	清华大学 力学与航空航天工程，本科（GPA: 3.8/4.0）	中国，北京

工作经历

基础模型研究实习生 阶跃星辰 StepFun	2026.05 - 至今
- 面向 Coding Agent 与 Working Agent 开展 SFT、RL 与 OPD 后训练实验，内部模型在 SWE-Pro 与 SWE-Atlas 上取得组内最佳结果；相关训练方案与实验结论正合入下一代模型的训练和迭代流程。 - 搭建基于 LLM Orchestration 的 Coding Agent 与 Working Agent 环境生成、优化和评测流水线，自动检查 Task 与 Rubric 的合理性和丰富度，以及工作目录、环境与附件的完整性，持续评估并提升环境质量。 - 定义并验证 Agent trace 中的 10+ 项失败模式指标，涵盖任务失败归因与长程任务上下文效率；在多款前沿 Coding 模型上对比指标命中率，分析不同模型的行为特征与失败模式。	
基础模型研究实习生 美团 LongCat 大模型团队	2025.09 - 2025.12
- 后训练 Qwen3-VL-32B 以增强物理世界推理能力，在 ERQA 上提升 4 分。 - 搭建 VLA 训练评测栈，完成 Pi0、Pi0.5 与 Isaac GR00T 在 LIBERO 的部署，并跑通 Pi 系列预训练与微调管线。 - 在 Arcade Learning Environment 中开发具备 Memory 的 VLM 游戏 Agent，通过持续学习和总结交互经验，使 GPT-4o 在 3 款 Atari 游戏中取得接近人类的分数。 - 以共同第一作者参与 3 篇多轮指令遵循与真实业务评测论文：SOP-Maze 已被 ACL Findings 2026 接收；EMNLP 投稿获 Meta Review 推荐 Findings 接收，另有 1 篇 AAAI 在投。	

研究经历

通用激活引导：基于流的激活引导用于推理时干预（第一作者） 佐治亚理工学院	2026.03 - 2026.05
- 提出 FLAS (Flow-based Activation Steering)，用于大语言模型推理时干预，建模多步、随 token 变化的激活轨迹。 - 在 AxBench 上实现零样本激活引导最优表现 (SOTA)，成为首个持续超越上下文提示的激活引导方法；以不到 4% 的参数量较 HyperSteer 提升 67%。 - 项目主页: flas-ai.github.io；入选 ICML 2026 机制可解释性研讨会海报展示；投稿 NeurIPS 2026 (5/4/4)。	
随机注意力：随机路由实现高表达力线性时间注意力机制（第一作者） 清华大学	2025.12 - 2026.04
- 提出随机注意力 (Stochastic Attention, SA)，通过 token 随机化路由实现无参数增强滑动窗口注意力 (Sliding Window Attention, SWA)；在 32K 序列长度下相比全注意力实现最高 28 倍加速。 - 采用门控 SA+SWA 双路径架构预训练 360M 参数语言模型，在 7 个基准上的平均零样本准确率超越此前最优方法。 - 论文: arXiv:2604.00754, under review。	
SOP-Maze：复杂业务标准作业流程中的大模型评测（共同第一作者） 美团 LongCat 大模型团队	2025.09 - 2025.12
- 提出 SOP-Maze，首个真实业务 SOP 大模型评测基准，包含 23 个复杂场景、397 个实例与 3,422 个子任务。 - 基于 JSON Schema 与参考索引匹配构建确定性评测框架，实现对开放式模型回复的可靠、高效评分。 - 论文: arXiv:2510.08942, ACL Findings 2026。	

荣誉奖项

英华学者	清华大学（全校 15 名本科生）	2022
星火计划	清华大学（全校 40 名本科生）	2023
综合优秀奖学金	清华大学前 5%	2022, 2024
国际大学生数学建模竞赛 (ICM) 特等奖提名 (Finalist)	全球参赛队伍前 2%	2023

专业技能

语言能力	英语流利（托福 109），中文母语
技术栈	PyTorch, Hugging Face Transformers, Megatron, vLLM, Python, C/C++
研究方向	基础模型后训练、LLM Agent、模型评测与机制可解释性